2026 극지 빅데이터-인공지능 활용 경진대회 데이터분석 부문

남극 세종과학기지 다중 기상·대기입자 빅데이터 기반 기온예측 모델 개발

- KPDC/NASA 데이터, XGBoost 머신러닝 모델을 중심으로

극지연구소
Korea Polar Research Institute

2026년 07월

팀 시원한 지성

팀장 이지성, 팀원 강시원

본 연구의 기온예측에는 DMLC가 개발·배포한 오픈소스 머신러닝 라이브러리 XGBoost 3.3.0의 XGBRegressor를 사용하였습니다.

Apache License 2.0에 따라 연구 목적의 모델 구축·학습·성능평가에 활용하였으며,

공개 사전학습 모델은 사용하지 않고 KPDC·NASA 자료를 이용하여 모델을 직접 학습하였습니다.

생성형 AI인 GPT-5.6 Thinking은 자료 조사, 머신러닝 코드 작성 및 웹페이지 제작 과정에서 보조적으로 활용하였습니다.

목 차

1. 서론 4

1.1 연구배경 및 목적

1.2 연구 범위 및 한계

2. 연구자료 및 데이터 전처리 5

2.1 관측지점, 장비 및 활용 자료

2.2 KPDC 자료 전처리 및 통합

2.3 NASA 자료 전처리 및 통합

2.4 MERRA-2 에어로졸 질량농도의 등가 수농도 변환

2.5 최종 분석 데이터셋 구성

3. 연구방법 8

3.1 입력변수 및 4종 모델 실험구조 설정

3.1.1 KPDC 지상 관측자료 기반 모델

3.1.2 NASA 자료 기반 모델

3.1.3 KPDC-NASA 결합자료 기반 모델

3.1.4 NASA 공통시점 KPDC 모델

3.2 탐색적 분석 및 변수관계 분석

3.3 기온예측 모델 선정 및 하이퍼파라미터 설정

3.4 학습·검증·시험자료 분할

3.5 모델 성능평가 지표 및 비교방법

4. 기온예측 성능평가 및 최적모델 생성 12

4.1 KPDC 기반 기온예측모델 성능

4.2 NASA 기반 기온예측모델 성능

4.3 KPDC-NASA 결합 기온예측모델 성능

4.4 NASA 기반 KPDC 자료 기온예측모델 성능

4.5 네 모델의 성능 비교 및 주요변수 해석

4.6 최적 하이퍼파라미터 기반 최종모델 선정 및 생성

5. 논의 및 결론 18

5.1 연구결과의 종합 해석

5.2 연구의 의의 및 활용

5.3 연구의 한계 및 후속 연구방향 제시

6. 참고문헌 22

1. 서론

1.1 연구배경 및 목적

극지방은 저온, 강풍, 결빙 등 가혹한 환경과 제한적인 접근성으로 인해 관측장비의 설치·점검 및 유지보수가 어렵고, 관측자료가 상대적으로 희소한 지역이다. 세계기상기구(WMO) 역시 극지방을 전통적인 기상관측자료가 부족한 지역으로 설명하고 있으며, 남극 자동기상관측소에서는 기계적 센서 고장과 극한 환경으로 인한 관측 장애가 지속적으로 보고되어 왔다. 특히 기온 센서에 고장이 발생하면 당시의 기상상태와 시간적 변화를 정확히 파악하기 어려워 관측자료의 연속성과 활용성이 저하될 수 있다.

이에 본 연구에서는 남극 세종과학기지를 대상으로 CN10 총입자수, 상대습도, 기압, 풍속, 풍향 및 시간정보를 활용하여 지상기온을 추정하는 예측모델을 구축하고자 한다. 또한 지상 관측자료뿐만 아니라 NASA CALIPSO 위성자료와 MERRA-2 재분석자료를 함께 활용하여, 자료 출처와 표본구성에 따른 기온예측 성능 차이 및 자료 결합의 효과를 비교하고자 한다.

본 연구의 주요 목적은 기온 센서의 고장으로 장기간 결측이 발생한 경우 기존 지상 관측자료를 기반으로 기온을 보조적으로 추정·복원할 수 있는 방법을 제시하는 데 있다. 더불어 지상 관측자료와 위성·재분석자료의 예측력을 동일한 조건에서 비교하고, 두 자료원의 결합이 지상기온 예측성능을 향상시키는지 검증함으로써 극지 관측자료의 보완 및 활용 가능성을 제시하고자 한다.

1.2 연구 범위 및 한계

본 연구는 남극 세종과학기지에서 관측된 2010~2019년 KPDC 기상·CN10 자료와 CALIPSO·MERRA-2 NASA 자료를 활용하여 기온예측모델을 구축하였다. 자료 구성에 따라 KPDC 단독모델, NASA 단독모델, KPDC-NASA 결합모델, 그리고 NASA시점 KPDC 모델의 네 가지 실험을 수행하고 각 자료의 예측 기여도를 비교하였다. 입경별 입자자료는 접근 범위의 제한으로 제외하고, KPDC의 CN10 총수농도와 MERRA-2 질량농도를 변환한 등가 수농도를 활용하였다. 다만 NASA 자료는 CALIPSO 통과시점이 제한적이고 MERRA-2가 공간평균 재분석자료이므로, 지상 관측자료와 표본수 및 시간·공간 해상도에 차이가 있다.

2. 연구자료 및 데이터 전처리

2.1 관측지점, 장비 및 활용 자료

본 연구의 기준 관측지점은 남극 킹조지섬에 위치한 세종과학기지이며, 한국극지데이터센터(KPDC)와 미국항공우주국(NASA)에서 제공하는 자료를 활용하였다.

먼저 지상자료는 2010~2019년 한국극지데이터센터(KPDC)의 AMOS 시간별 기상자료와 응축입자계수기 CPC3772의 입자 관측자료를 활용하였다. AMOS 자료에서는 기온, 상대습도, 기압, 풍속 및 풍향을 사용하였으며, CPC3772 자료에서는 입경 10 nm 이상 입자의 총수농도인 CN10을 활용하였다.

다음으로 위성자료는 미국항공우주국(NASA)에서 제공하는 자료를 수집하였으며, 중심좌표는 위도 62.2167° S, 경도 58.7833° W이며 자료처리 코드에서는 각각 -62.22° , -58.78° 로 설정하여 추출하였다.

CALIPSO 자료는 L2 5 km Aerosol Profile V5.00 제품을 대상으로 하였으며, 세종과학기지 주변을 통과하는 위성궤도의 관측시각·위도·경도 및 고도정보를 활용하였다. CALIPSO 자료는 CALIOP 라이다를 이용한 에어로졸 수직 프로파일을 제공하며, 제품 내 기온·상대습도·기압은 라이다가 직접 측정한 값이 아니라 프로파일 처리와 해석을 위해 함께 제공되는 보조 기상자료이다. 본 연구에서는 각 프로파일과 세종기지 사이의 거리를 계산한 뒤, 지표고도를 제외한 지상고도 0.3~1.5 km AGL 구간의 위도·경도·대표고도·상대습도·기압 및 관측시각을 추출하여 위성 통과별로 평균하였다. CALIPSO 자료에 포함된 기온은 지상기온 목표변수와 직접적으로 유사한 정보를 포함할 수 있으므로 모델 입력에서는 제외하였다.

MERRA-2 자료는 세종기지에 가장 가까운 위도 3개와 경도 3개를 선택하는 방식으로 추출하였으며, 적용된 범위는 위도 -62.50° , -62.00° , -61.50° 와 경도 -59.375° , -58.750° , -58.125° 로 구성된 총 9개 격자이다. MERRA-2의 M2T1NXAER 자료에서는 먼지, 해염, 황산염, 유기탄소 및 검댕의 지표 질량농도를, M2T1NXSLV 자료에서는 10 m 동서·남북 바람성분을 추출한 뒤 9개 격자를 공간평균하고 풍속·풍향과 총에어로졸 질량농도를 산출하였다.

2.2 KPDC 자료 전처리 및 통합

KPDC 지상 관측자료는 2010~2019년 세종과학기지의 AMOS 기상자료와 CPC 입자관측자료로 구성하였다.

CPC 입자관측자료는 dat 파일에 포함된 입경 10 nm 이상 및 2.5 nm 이상 입자 수농도 중 본 연구의 범위에 해당하는 CN10 총 수농도만을 선택하여 활용하였다. 또한 분석기간에 해당하는 약 10년간의 파일을 연속적으로 수집하였고, 각 파일의 날짜와 내부 시각정보를 결합하여 KPDC 관측기준인 UTC-4 기준의 관측시각을 생성하고 초 단위 관측값을 1시간 단위로 집계하여 시간별 총입자 수농도 자료를 구성하였다.

AMOS 기상자료는 처음부터 1시간 단위로 제공되었으며, 기온, 상대습도, 기압, 풍속 및 풍향이 시간 단위로 기록된 일별 .dat 파일로 제공되었다. 시간 단위로 변환된 CPC의 CN10 자료와 AMOS 자료를 UTC 시각을 기준으로 정렬한 뒤, 동일 시각에 두 자료가 모두 존재하는 공통 관측시점만을 기준으로 결합하였다. 또한 동일 시각의 중복자료와 결측자료를 확인하였으며, 풍향은 0° 와 360° 가 같은 방향을 의미하는 순환형 변수이므로 모델링 단계에서 사인과 코사인 성분으로 변환하였다.

$$U = -WSsin\left(\theta\frac{\pi}{180}\right), \qquad V = -WScos\left(\theta\frac{\pi}{180}\right)$$

최종적으로 기온을 목표변수로 설정하고 CN10, 상대습도, 기압, 풍속, 풍향 및 시간 관련 변수를 입력변수로 하는 약 8.8만 개의 시간별 KPDC 통합 데이터셋을 구성하였다. 이후 모델링 단계에서 관측시각을 UTC 기준으로 추가 변환하여 NASA 자료와 동일한 시간 기준을 적용하였다.

*제출파일 : 데이터셋1 : [KPDC_atmo_CN10_merged_deg_transfer.csv]

2.3 NASA 자료 전처리 및 통합

NASA 자료는 2010~2019년을 대상으로 CALIPSO 위성 관측자료와 MERRA-2 재분석자료를 수집하여 통합하였다.

CALIPSO 자료는 세종과학기지를 중심으로 100 km × 100 km 사각형, 최대 반경 약 71 km, 지표면 기준 고도 0.3~1.5 km 범위에서 관측된 시각 · 위치 · 고도 · 상대습도 · 기압 · 기온 변수를 추출하였으며, CALIPSO 프로파일별 위도와 경도가 위성 이동 경로에 따라 제공되는 점을 활용하였다.동일 위성 통과에서 수초 간격으로 연속 생성된 자료는 서로 독립된 관측사건으로 보기 어려우므로, 연속 관측 간 시간 차이가 5분 이내인 자료를 하나의 통과군으로 묶고 변수별 산술평균을 산출하였다.

MERRA-2는 CALIPSO 관측이 존재하는 날짜만을 대상으로 에어로졸 질량농도 자료와 10 m 풍속 · 풍향 자료를 추출하였으며, 세종과학기지 주변의 대기환경을 대표하도록 인접한 3×3 고정 격자를 선정하였다. MERRA-2의 공간해상도는 위도 0.5° , 경도 0.625° 이고 2차원 변수는 1시간 간격으로 제공되므로, 9개 격자의 값을 시각별로 공간평균하여 지역 대표값을 구성하였다. 풍향은 0° 와 360° 가 동일한 순환형 변수이므로 단순 산술평균을 적용하지 않고, 풍속과 풍향을 동서 · 남북 바람성분으로 변환한 후 벡터평균하여 대표 풍속과 풍향을 재산출하였다.

이후 각 CALIPSO 통과 대표시각이 포함되는 MERRA-2의 1시간 평균구간을 기준으로 최대 30분 이내의 자료를 대응시켰으며, CALIPSO 관측사건을 보존하기 위해 CALIPSO 기준으로 결합을 적용하였다. 최종적으로 1,028개의 CALIPSO 통과사건에 MERRA-2 변수를 결합하였고, MERRA-2 에어로졸 질량농도는 KPDC의 CN10 수농도와 단위 및 물리적 의미가 다르므로 후속 절에서 등가 수농도로 변환하였다.

* 제출파일 : 데이터셋2 [CALIPSO_MERRA2_merged_deg_transfer.csv]

2.4 MERRA-2 에어로졸 질량농도의 등가 수농도 변환

MERRA-2에서 제공되는 에어로졸 자료는 단위 부피당 입자의 질량을 나타내는 질량농도($\mu g/m^3$)인 반면, 세종과학기지의 CPC3772 자료는 입경 10 nm 이상 입자의 개수를 나타내는 수농도(cm^{-3})이므로 두 자료를 그대로 비교하기 어렵다. 이에 본 연구에서는 MERRA-2의 먼지, 해염, 황산염, 유기탄소 및 검댕 성분별 질량농도를 합산하여 총에어로졸 질량농도 M을 산출하고, 이를 일정한 밀도와 유효반지름을 갖는 구형입자의 등가 수농도로 변환하였다. 구형입자 한 개의 질량은 다음 식으로 계산하였다.

$$\text{입자 1개의 질량} = \frac{4}{3}\,\pi\,(\text{입자밀도}) \times (\text{유효반지름})^3$$

따라서 MERRA-2 총질량농도 M을 등가 수농도 N으로 변환하는 식은 다음과 같이 설정하였다.

$$N = \frac{(M \times 10^{12})}{(4/3)\pi \times \rho \times R^3}$$

여기서 M은 MERRA-2 총질량농도($\mu g/m^3$), N은 등가 수농도(cm^{-3}), ρ는 입자밀도(kg/m^3), R은 등가 유효반지름(nm)을 의미하며, 10^{12}은 $\mu g/m^3$ 와 kg · nm · cm 단위 간 변환을 반영한 계수이다. 다만 위 식에서는 밀도와 반지름이 ‘ρ × R^3 ’ 의 형태로 함께 작용하므로, KPDC CN10과 MERRA-2 질량농도만으로 두 값을 동시에 독립적으로 결정할 수 없다. 성분별 대표밀도는 NASA GEOS/GOCART 문서에서 제시한 MERRA-2 에어로졸의 건조밀도를 기준으로 설정하였다. 먼지는 입경구간에 따라 2,500~2,650 kg/m^3 , 해염은 2,200 kg/m^3 , 황산염은 1,700 kg/m^3 , 탄소질 에어로졸은 1,800 kg/m^3 의 밀도를 적용하였다. 이후 각 시점의 성분별 질량비를 이용하여 혼합밀도를 산정하였으며, NASA 통합자료 1,028건에서 계산된 혼합밀도의 중앙값 2,159.70 kg/m^3 를 10 kg/m^3 단위로 반올림하여 고정밀도 2,160 kg/m^3 를 설정하였다.

유효반지름은 MERRA-2 총질량농도와 KPDC CN10이 동시에 확보된 시점을 이용하여 경험적으로 산정하였다. MERRA-2 시간자료가 매시 30분을 대표시각으로 가지므로, 해당 시각 전후의 KPDC 정시 CN10 값을 선형보간하여 MERRA-2와 동일한 시각의 CN10을 생성하였다. 이 과정에서 결측값과 0 이하의 질량농도 또는 CN10을 제외한 결과 총 919개의 유효 동시자료쌍이 확보되었다. 이후 원자료 기준 RMSE 및 MAE 최소화, 로그 변환자료 기준 RMSE 및 MAE 최소화, 10% 절사평균, 로그 Huber 손실 등 총 여섯 가지 방법을 적용하여 유효반지름 후보를 산정하였다. 또한 특정 연도의 관측특성이 최종 반지름에 과도하게 반영되지 않도록 한 연도씩 제외하여 반지름을 산정한 후 제외된 연도에서 성능을 평가하는 leave-one-year-out 교차검증을 수행하였다.

비교 결과, 원자료 RMSE 방법은 일부 고농도 CN10 사례의 영향을 크게 받았으며, 원자료 MAE 방법은 고농도 구간의 상대적 오차를 충분히 반영하지 못하였다. 반면 로그 공간에서 계산한 방법은 질량농도와 수농도가 여러 자릿수 범위로 변화하는 에어로졸 자료의 특성을 안정적으로 반영하였다. 특히 로그 Huber 방법은 작은 오차에는 제곱오차를 적용하면서 큰 오차에는 선형 가중치를 적용하므로, 일반적인 관측값을 충분히 반영하면서도 고농도 사건과 이상값의 영향을 제한할 수 있다. 로그 Huber 방법은 비교한 여섯 가지 방법 중 교차검증 로그오차가 가장 낮았으며, 연도별로 산정된 반지름의 변동계수도 약 0.84%로 가장 안정적이었다. 이에 전체 919개 동시자료를 다시 적용하여 최종 등가 유효반지름을 210.94 nm, 즉 약 0.2109㎛로 결정하였다. 이때 산출된 질량농도-수농도 변환계수는 11.77591 cm^{-3} /($\mu g/m^3$)이다.

최종적으로 고정밀도 2,160 kg/m^3 와 유효반지름 210.94nm를 변환식에 대입하면 다음의 간략한 변환관계가 도출된다.

$$\text{등가 수농도}\ (cm^{-3}) = 11.77591 \times \text{MERRA} - 2\ \text{총질량농도}\ (\mu g/m^3)$$

이에 따라 NASA 통합자료의 모든 행에 대해 MERRA-2 총질량농도에 11.77591을 곱하여 estimated_cn10_cm3 변수를 다시 생성하였다. 예를 들어 MERRA-2 총질량농도가 10 $\mu g/m^3$ 인 경우 등가 수농도는 약 117.76 cm^{-3} 로 계산된다. 다만 산정된 210.94 nm는 실제 대기입자의 평균반지름이나 입경분포의 최빈값을 의미하지 않으며, MERRA-2 총질량농도와 CPC3772 CN10의 전체적인 규모를 하나의 구형입자로 대응시킨 질량 등가 유효반지름이다. 따라서 estimated_cn10_cm3는 실제 CPC 관측값을 직접 대체하기보다는, 서로 다른 단위의 MERRA-2와 KPDC 에어로졸 자료를 비교하고 NASA 확장모델에 투입하기 위한 보조적인 등가 수농도 변수로 활용하였다.

* 제출파일 : 데이터셋3 : [CALIPSO_MERRA2_merged_estimated_CN10.csv]

2.5 최종 분석 데이터셋 구성

최종 분석자료는 KPDC 지상 관측자료와 NASA 확장자료의 두 종류로 구성하였다.

KPDC 통합자료인 KPDC_atmo_CN10_merged.csv 는 AMOS의 기온·상대습도·기압·풍속·풍향과 CPC3772의 CN10을 시간 기준으로 결합한 87,923개 관측행으로 구성되며, 모델링에서는 필수변수가 모두 존재하는 약 8.8만 개의 공통자료를 사용한다. NASA 최종자료인 calipso_merra2_merged_estimated_cn10.csv는 CALIPSO 저층 대기관측과 MERRA-2 주변 3×3 격자 공간평균자료를 결합한 1,028개 관측행으로 구성하였다. 해당 자료에는 CALIPSO와 MERRA-2의 원래 기상·에어로졸 변수와 함께, 고정밀도 2,160 kg/m^3 및 유효반지름 210.94 nm를 적용하여 산출한 estimated_cn10_cm3가 포함된다.

3. 연구방법

3.1 입력변수 및 4종 모델 실험구조 설정

본 연구에서는 자료원별 예측력, 표본구성의 영향 및 자료 결합 효과를 비교하기 위해 KPDC 전체표본 기반, NASA 관측시점 KPDC 공통표본 기반, NASA 기반, KPDC-NASA 결합 기반의 4종 기온예측모델을 구성하였다. 모든 모델의 목표변수는 세종과학기지의 지상기온으로 통일하였으며, 입력변수는 습도, 기압, 바람성분, CN10 관련 변수, 시간정보 및 자료별 고유 관측변수로 설정하였다.

풍향과 풍속은 방향의 순환적 특성을 반영하기 위해 동서·남북 바람성분으로 변환하였고, CN10은 큰 값의 영향을 줄이고 분포의 치우침을 완화하기 위해 log1p 변환을 적용하였다. 또한 UTC+0 기준 관측시각에서 시간과 연중일을 추출한 뒤 사인·코사인 순환형 변수로 변환하여 일변화와 계절성을 반영하였다. NASA와 KPDC 자료는 동일한 시간 기준으로 통일한 뒤 최근접 시각을 기준으로 결합하였으며, 목표변수인 지상기온은 모든 입력변수에서 제외하여 정보 누수를 방지하였다.

KPDC 전체표본 모델은 2010~2019년의 전체 지상 관측자료를 활용하여 지상자료만으로 얻을 수 있는 실용적 기온예측 성능을 평가하기 위한 기준모델로 설정하였다. NASA 관측시점 KPDC 공통표본 모델은 NASA 자료가 존재하는 시점에 대응되는 KPDC 자료만을 사용하여, NASA 기반 모델 및 결합모델과 동일한 표본조건에서 비교하기 위한 통제모델로 구성하였다. NASA 기반 모델은 CALIPSO 위성자료와 MERRA-2 재분석자료만으로 지상기온을 추정함으로써 위성·재분석자료의 독립적인 활용 가능성을 평가하도록 하였다. KPDC-NASA 결합모델은 동일한 공통표본에서 지상 관측자료와 위성·재분석자료를 함께 사용하여, NASA 자료의 추가가치와 다중 자료원 결합에 따른 예측성능 향상 여부를 검증하도록 설정하였다.

이에 따라 KPDC 전체표본 모델과 KPDC 공통표본 모델의 비교를 통해 표본 수와 관측밀도의 영향을 확인하고, KPDC 공통표본 모델과 NASA 기반 모델의 비교를 통해 동일한 시점에서 지상자료와 위성·재분석자료의 예측력을 비교하였다. 또한 KPDC 공통표본 모델과 KPDC-NASA 결합모델을 비교하여 NASA 자료의 추가효과를 평가하고, NASA 기반 모델과 결합모델을 비교하여 지상 관측자료의 보완 효과를 함께 분석하였다.

3.1.1 KPDC 지상 관측자료 기반 모델

KPDC 지상 관측자료 기반 모델은 세종과학기지에서 2010~2019년 동안 수집된 기상·대기입자 자료 전체를 이용하여 지상기온을 예측하도록 구성하였다. 목표변수는 동일 시각의 지상기온 Ta (° C)이며, 입력변수로 상대습도 RH(%), 해면기압 SLP(hPa), 동서·남북 바람성분 Wind_U와 Wind_V, 총입자수농도 CN10 및 시간정보를 사용하였다. CN10은 고농도 값의 영향을 완화하기 위해 log1p 변환한 KPDC_CN10_log1p로 적용하였으며, 관측시각에서 시간과 연중일을 추출해 사인·코사인 순환형 변수로 변환하였다. KPDC 원자료의 시각은 LST(UTC-4) 기준이므로 4시간을 더해 UTC+0으로 통일하였고, 동일 시각의 중복자료는 변수별 평균으로 통합하였다. 최종 학습자료 구성 단계에서는 입력변수와 목표변수가 동일하게 반복된 중복행을 제거하여 동일한 지상 관측사례가 모델 학습에 중복 반영되지 않도록 하였다. 본 모델은 장기간의 지상 관측자료를 충분히 활용할 수 있는 경우의 기온예측 성능을 평가하는 실용적 기준모델로 설정하였다.

3.1.2 NASA 자료 기반 모델

NASA 자료 기반 모델은 CALIPSO 위성관측자료와 MERRA-2 재분석자료만을 이용하여 세종과학기지의 지상기온을 예측하도록 구성하였다. 입력변수로 CALIPSO 관측지점의 위도, 경도, 지상 기준 고도, 상대습도, 기압, 평균 프로파일 수 및 관측 시간범위를 사용하였으며, MERRA-2 자료에서는 유효 혼합밀도와 동서·남북 바람성분을 활용하였다. 에어로졸 질량농도로부터 환산한 NASA 추정 CN10은 log1p 변환하여 입력하였다. 또한 CALIPSO-MERRA-2 자료 간 시간차와 NASA 관측시점-KPDC 지상기온 간 매칭 시간차를 포함하여 자료 결합의 시간적 불확실성을 반영하였다. 모든 시각은 UTC+0 기준으로 통일하였고, 시간과 연중일을 사인·코사인 순환형 변수로 변환하였다. 목표변수는 각 NASA 관측시점과 최대 30분 이내에서 최근접 매칭된 KPDC 지상기온으로 설정하였으며, KPDC의 기상·입자 변수는 입력에서 제외하여 NASA 자료의 독립적인 지상기온 예측성능을 평가하였다. 또한 CALIPSO와 MERRA-2 자료의 통합 및 KPDC 목표기온 매칭이 완료된 후 동일한 입력변수와 목표값을 갖는 중복행을 제거하여 각 NASA 관측사례가 한 번만 반영되도록 하였다.

3.1.3 KPDC-NASA 결합자료 기반 모델

KPDC-NASA 결합자료 기반 모델은 CALIPSO·MERRA-2 자료와 KPDC 지상 관측자료를 동일한 시간축으로 통합하여 세종과학기지의 지상기온을 예측하도록 구성하였다. CALIPSO와 MERRA-2 시각은 UTC+0 기준으로 처리하고, KPDC 시각은 LST(UTC-4)에서 UTC+0으로 변환한 뒤 최대 30분 이내의 최근접 관측값을 매칭하였다. 입력변수에는 NASA 기반 모델의 위도, 경도, 지상 기준 고도, 상대습도, 기압, 평균 프로파일 수, 관측 시간범위, 유효 혼합밀도, 바람성분, 추정 CN10 및 자료 간 시간차를 포함하였다. 여기에 KPDC의 상대습도, 해면기압, 동서·남북 바람성분과 log1p 변환 CN10을 추가하였으며, 시간과 연중일은 사인·코사인 순환형 변수로 변환하였다. NASA와 KPDC 자료를 최근접 시각으로 결합한 뒤 동일한 입력변수와 목표값으로 반복된 결합행을 제거하여 중복 관측에 따른 학습 편향을 방지하였다. 목표변수는 결합 시점에 대응하는 KPDC 지상기온으로 설정하고 입력에서는 제외하였다. 본 모델은 NASA 시간기반 KPDC 모델과 비교하여 NASA 자료의 추가효과를 평가하고, NASA 기반 모델과 비교하여 지상 관측자료 결합에 따른 성능 개선을 확인하도록 설정하였다.

3.1.4 NASA 공통시점 KPDC 모델

NASA 시간기반 KPDC 자료 기반 모델은 NASA 관측시점과 최대 30분 이내에서 최근접 매칭된 KPDC 지상 관측자료만을 이용하여 세종과학기지의 지상기온을 예측하도록 구성하였다. 목표변수와 입력변수는 KPDC 지상 관측자료 기반 모델과 동일하게 설정하였으며, 상대습도 RH(%), 해면기압 SLP(hPa), 동서·남북 바람성분 Wind_U와 Wind_V, log1p 변환 CN10 및 시간 순환형 변수를 활용하였다. 다만 2010~2019년 전체 KPDC 자료를 사용하는 것이 아니라, CALIPSO·MERRA-2 자료가 존재하는 시점에 대응되는 KPDC 관측행만을 추출하였다. 모든 시각은 UTC+0 기준으로 통일하였고, 목표 기온은 입력변수에서 제외하였다. NASA 관측시점에 매칭된 KPDC 자료 중 동일한 입력변수와 목표값을 갖는 중복행을 제거하여 공통표본 내 각 지상 관측사례가 한 번만 사용되도록 하였다. 본 모델은 NASA 기반 및 KPDC-NASA 결합모델과 동일한 표본조건에서 성능을 비교하기 위한 통제모델로 활용하였으며, 결합모델과의 비교를 통해 NASA 자료 추가에 따른 순수한 예측성능 개선 효과를 평가하였다.

3.2 탐색적 분석 및 변수관계 분석

모델 학습에 앞서 KPDC와 NASA 자료의 관측기간, 전체 표본 수, 연도별 표본분포, 결측값 및 중복시각을 점검하였다.

KPDC 자료에서는 기온·상대습도·해면기압·풍속 및 CN10의 기술통계와 값의 범위를 확인하고, 물리적으로 허용되지 않는 결측코드와 이상값의 포함 여부를 검사하였다. CN10은 소수의 고농도 값으로 인해 오른쪽으로 치우친 분포를 보여 log1p 변환을 적용하였으며, 변환 전후의 분포를 비교하였다. 풍향은 0° 와 360° 가 동일한 순환형 변수이므로 풍속과 결합하여 동서·남북 바람성분으로 변환하였다.

NASA 자료에서는 CALIPSO 통과사건의 연도별 분포와 위도·경도·고도범위를 확인하고, MERRA-2 및 KPDC 자료와의 실제 매칭 시간차가 최대 30분 이내인지 확인하였다. 또한 네 모델의 입력변수와 목표 기온 간 관계는 XGBoost의 Gain 중요도와 최종모델의 SHAP 값을 이용하여 비선형관계와 변수별 예측 기여도를 분석하였다. 이를 통해 자료별 표본구성과 변수분포를 확인한 뒤 동일한 전처리 기준을 적용하여 최종 학습자료를 구성하였다.

3.3 기온예측 모델 선정 및 하이퍼파라미터 설정

본 연구의 입력자료는 기온, 습도, 기압, 바람 및 입자농도 사이의 비선형 관계와 변수 간 상호작용을 포함하므로, 이를 별도의 함수형 가정 없이 학습할 수 있는 트리 기반 부스팅 모델이 적합하다고 판단하였다. 특히 머신러닝 모델 'XGBoost'는 목적함수에 정규화항을 포함하여 복잡도를 제어하고, 표본 및 변수 부분추출을 통해 과적합을 완화할 수 있으며, 이러한 자료 특성과 기존 기상·원격탐사 연구에서 확인된 활용성을 근거로 XGBoost를 본 연구의 기온 추정 알고리즘으로 선정하였다.

XGBoost의 성능은 트리 깊이, 학습률 및 규제조건에 따라 크게 달라질 수 있으므로, [learning_rate, max_depth, min_child_weight, subsample, colsample_bytree, reg_alpha, reg_lambda, gamma] 총 8개 하이퍼파라미터를 탐색하였다. KPDC 모델은 약 8.8만 개의 연속 지상관측자료를 사용하므로 비교적 넓은 트리 깊이와 규제범위를 설정하였다. 반면 NASA 및 결합모델은 약 1천 개 수준의 표본을 사용하므로 과적합을 억제하기 위해 최대 트리 깊이와 최소 자식노드 가중치 범위를 상대적으로 제한하였다. 결합모델은 NASA 단독모델보다 입력변수가 많다는 점을 고려하여 열 표본추출 비율과 규제강도의 탐색범위를 확대하였다. 각 외부 시험연도에서 내부 연도별 교차검증을 수행하고, 검증 RMSE가 가장 낮은 하이퍼파라미터 조합을 해당 시험연도의 최적 조합으로 선정하였다.

하이퍼파라미터	KPDC 모델, NASA 공통시점 KPDC 모델	NASA 모델	KPDC-NASA 결합모델
Learning rate	0.01,0.02,0.03,0.05,0.08	0.01,0.02,0.03,0.05,0.08	0.01,0.02,0.03,0.05,0.08
Max depth	2,3,4,5,6,7	2,3,4,5	2,3,4,5,6
Min child weight	1,3,5,10,20,50	2,3,5,8,12,20	2,3,5,8,12,20
Subsample	0.7,0.8,0.9,1.0	0.8,0.9,1.0	0.8,0.9,1.0
Colsample bytree	0.70, 0.80, 0.90, 1.00	0.65, 0.75, 0.85, 0.95, 1.00	0.60, 0.70, 0.80, 0.90, 1.00
Reg alpha	0.00, 0.01, 0.10, 0.50, 1.00, 2.00	0.00, 0.05, 0.10, 0.50, 1.00, 2.00	0.00, 0.05, 0.10, 0.50, 1.00, 2.00
Reg lambda	0.50, 1.00, 2.00, 5.00, 10.00, 20.00	1.00, 2.00, 5.00, 10.00, 20.00	1.00, 2.00, 5.00, 10.00, 20.00
gamma	0.00, 0.05, 0.10, 0.30, 0.50, 1.00, 2.00	0.00, 0.05, 0.10, 0.30, 0.50, 1.00	0.00, 0.05, 0.10, 0.30, 0.50, 1.00

[표 3.1 하이퍼파라미터 범위]

모델 간 성능 차이가 하이퍼파라미터 탐색범위의 차이가 아니라 입력자료와 표본구성의 차이에서 발생하도록 하기 위해 NASA 기반 KPDC 모델은 KPDC_ONLY와 동일한 탐색조건을 적용하였다. 전체 조합을 전수 탐색하지 않고 각 모델의 탐색공간에서 30개 조합을 무작위 추출하여 계산량을 제한하였으며, 각 조합은 내부 교차검증 평균 RMSE를 기준으로 비교하였다.

3.4 학습 · 검증 · 시험자료 분할

KPDC 원자료는 87,923행으로, 동일시각 중복자료를 평균 통합한 뒤 약 8.8만 개의 시간별 표본을 사용하였으며, NASA 자료는 1,028개 관측치 중 품질조건과 KPDC 시간매칭을 충족한 약 1천 개를 사용하였다. 자료를 무작위로 나누면 동일 연도의 계절 · 기상패턴이 학습과 시험자료에 함께 포함될 수 있으므로, 2010~2019년을 기준으로 중첩 연도 교차검증을 적용하였다. 외부 교차검증에서는 한 연도를 시험자료로 완전히 분리하고 나머지 9개 연도를 학습 · 검증 후보로 사용하였으며, 이를 10개 연도에 대해 반복하였다.

각 외부 반복의 내부 검증은 연도를 유지한 3-fold Group K-fold로 구성하여, 6개 연도를 학습하고 3개 연도를 검증하는 방식으로 하이퍼파라미터를 선정하였다. 선정된 파라미터와 내부 검증에서 결정된 트리 수를 이용해 시험연도를 제외한 9개 연도 전체를 다시 학습한 뒤, 격리된 1개 연도를 테스트 데이터로 활용하여 최종 성능을 산출하였다. 시험연도는 최종 성능평가에만 사용하고, 하이퍼파라미터 선택 · 조기종료 및 최적 반복횟수 결정에는 활용하지 않았으며 연도 단위 분할을 통해 같은 연도의 시간적으로 인접한 관측값이 학습과 검증자료에 동시에 포함되지 않도록 하였다.

3.5 모델 성능평가 지표 및 비교방법

모델 성능은 예측오차의 크기와 설명력을 함께 확인하기 위해 RMSE, MAE 및 결정계수 R^2등을 활용하여 평가하였다. RMSE는 큰 예측오차에 더 높은 가중치를 부여하므로 급격한 기온변화나 이상 예측에 대한 민감도를 확인하는 주 지표로 사용하였고, 하이퍼파라미터 선정 역시 내부 검증 RMSE를 기준으로 수행하였다.

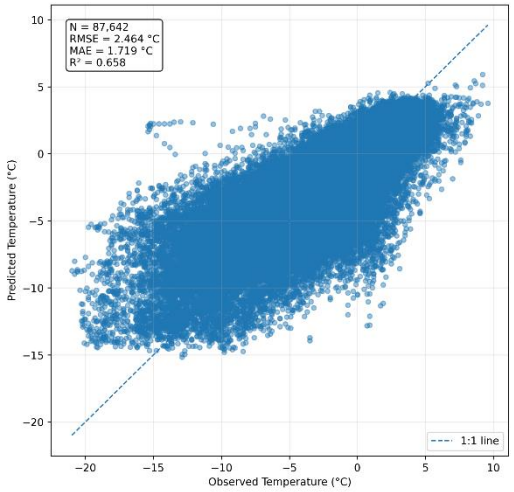
MAE는 각 예측값이 실제 기온과 평균적으로 몇 °C 차이 나는지를 직관적으로 제시하기 위해 함께 산출하였다. R^2는 관측된 기온 변동을 모델이 어느 정도 설명하는지 평가하는 지표로 활용하되, 특정 연도의 기온 분산에 따라 값이 달라질 수 있어 오차지표와 함께 보조적으로 해석하였다. 외부 교차검증에서 분리된 각 시험연도의 지표를 개별 산출하고, 10개 연도의 예측값을 결합한 전체 OOF 예측에서도 종합 성능을 계산하였다. KPDC 모델은 장기간 지상자료 기반 성능을 평가하고, NASA 단독모델과 결합모델은 동일한 NASA 관측시점과 동일한 목표기온 표본을 사용하여 입력자료 추가 효과를 직접 비교하였다.

각 모델의 최적 하이퍼파라미터는 내부 연도별 교차검증에서 무작위로 추출한 30개 조합 가운데 평균 RMSE가 가장 낮은 조합으로 선정하였다. 동일한 검증표본에서는 제곱오차가 감소할수록 R^2도 증가하지만, R^2는 연도별 기온 분산에 영향을 받으므로 서로 다른 연도 간 성능을 일관되게 비교하기 어렵다. 이에 실제 기온과 동일한 °C 단위로 해석할 수 있고 큰 예측오차에 더 큰 패널티를 부여하는 RMSE를 주 선정지표로 사용하였으며, R^2과 MAE를 함께 검토하여 기온 변동에 대한 설명력이나 평균오차가 현저히 저하되는 조합은 배제하였다. 평균 RMSE가 유사한 경우에는 연도별 RMSE 편차가 작은 조합을 우선하고, 최종적으로 선정된 설정을 적용하여 2010~2019년 전체자료로 네 개의 최종모델을 각각 학습하였다.

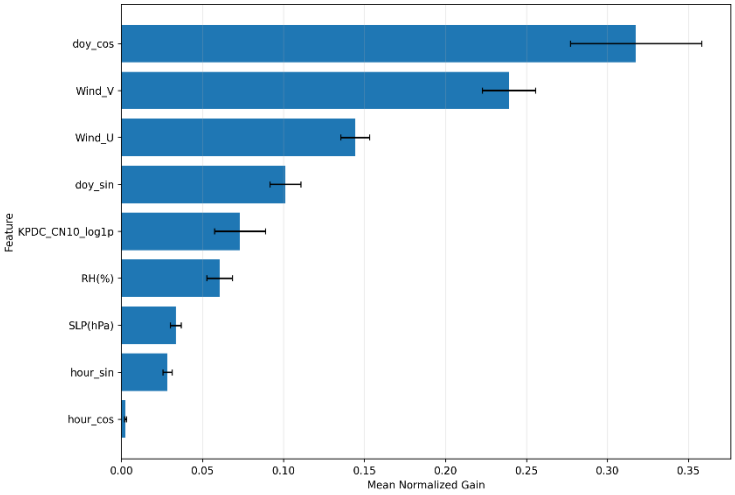
4. 기온예측 성능평가 및 최적모델 생성

4.1 KPDC 기반 기온예측모델 성능

KPDC 기반 기온예측모델은 2010~2019년의 지상 관측자료 87,642개를 이용하여 중첩 연도 교차검증으로 성능을 평가하였다. 외부 시험연도 10개에 대한 평균 성능은 MAE 1.719±0.187℃, RMSE 2.449±0.293℃, R^2 0.635±0.102로 나타났다. 전체 외부 시험예측을 통합한 결과에서는 MAE 1.719℃, RMSE 2.464℃, R^2 0.658이었으며, 평균 편향은 −0.017℃로 체계적인 과대·과소예측은 크지 않았다. 연도별 RMSE는 2.089~3.009℃ 범위로, 2016년의 오차가 가장 작고 2011년의 오차가 가장 크게 나타나 연도별 기상조건에 따른 성능 차이가 확인되었다.

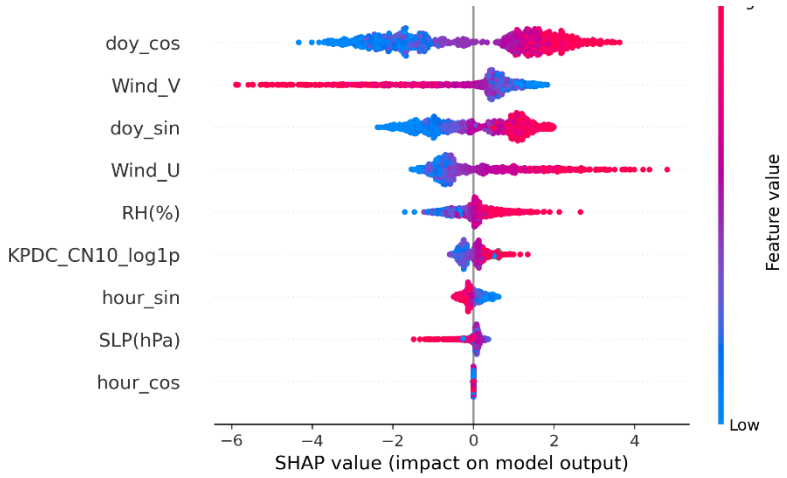


[그림 4.1 KPDC 기반 기온예측모델의 외부 시험자료 실제값-예측값 분포]



[그림 4.2 KPDC 기반 Gain 중요도]

실제값과 예측값은 전반적으로 유사한 방향의 분포를 보였으나, 매우 낮거나 높은 기온에서는 예측값이 평균적인 범위로 수렴하는 경향이 나타났다. 평균 Gain 기준 변수 중요도는 연중일 코사인 변수인 doy_cos가 가장 높았으며, 남북·동서 바람성분과 doy_sin이 뒤를 이었다.

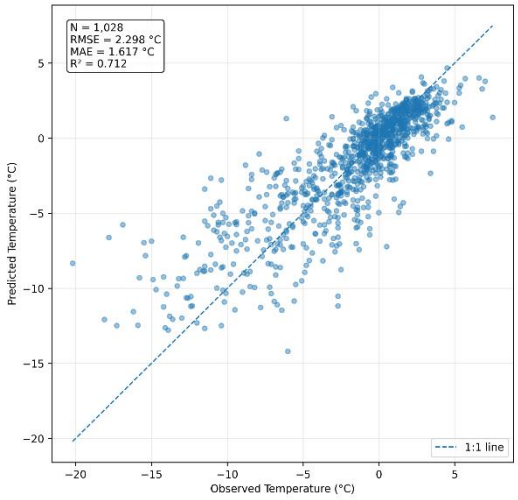


[그림 4.3 KPDC 기반 최종모델의 SHAP 변수 영향 분석]

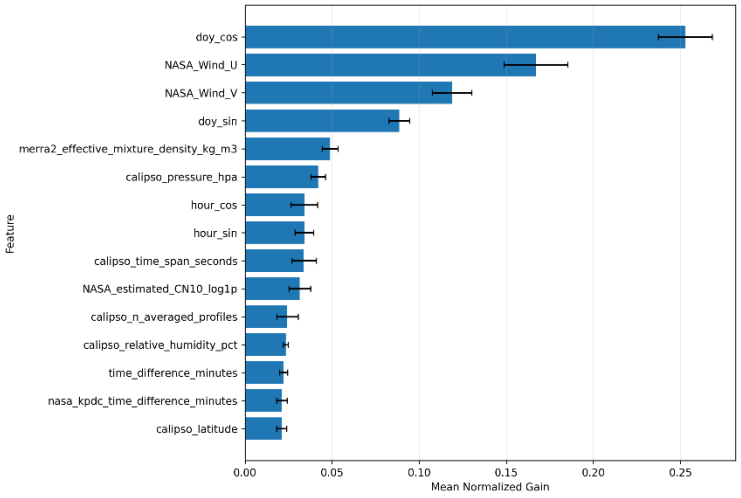
SHAP 분석에서도 계절 순환변수와 바람성분의 영향이 가장 크게 나타났고, 상대습도와 CN10은 이를 보완하는 변수로 활용되었다. 이는 KPDC 모델이 주로 계절성과 풍계 변화를 통해 지상기온 변동을 학습하면서, 대기입자와 기상변수를 추가 정보로 반영했음을 의미한다.

4.2 NASA 기반 기온예측모델 성능

NASA 기반 기온예측모델은 CALIPSO · MERRA-2 자료와 KPDC 지상기온이 매칭된 1,028개 표본을 이용하여 중첩 연도 교차검증으로 성능을 평가하였다. 외부 시험연도 10개에 대한 평균 성능은 MAE 1.618±0.181℃, RMSE 2.283±0.301℃, R^2 0.700±0.067로 나타났다. 전체 외부 시험예측을 통합한 결과에서는 MAE 1.617℃, RMSE 2.298℃, R^2 0.712였으며, 평균 편향은 0.021℃로 전체적인 과대 · 과소예측 편향은 크지 않았다.

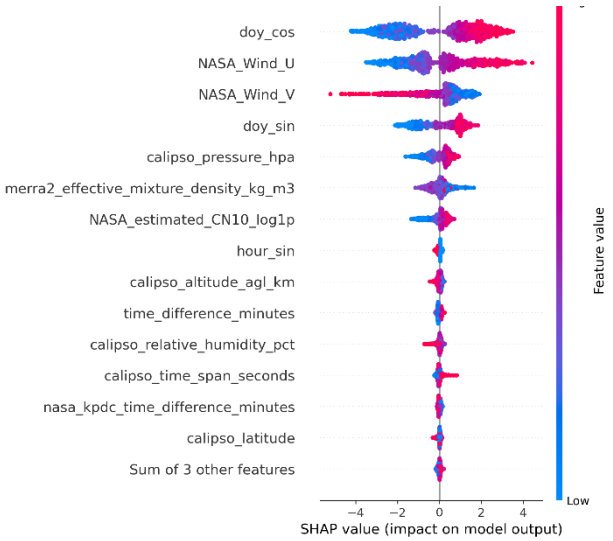


[그림 4.4 NASA 기반 기온예측모델의 외부 시험자료 실제값-예측값 분포]



[그림 4.5 NASA 기반 Gain 중요도]

연도별 RMSE는 1.766~2.790℃ 범위로, 2016년의 예측오차가 가장 작고 2011년의 오차가 가장 크게 나타났다. 실제기온과 예측기온은 전반적으로 양의 상관관계를 보였으나, 매우 낮은 기온에서는 예측값이 실제값보다 높은 범위로 수렴하여 극저온 변동을 일부 완화해 예측하는 경향이 확인되었다. 평균 Gain 기준으로는 doy_cos의 중요도가 가장 높았으며, NASA 동서 · 남북 바람성분과 doy_sin이 뒤를 이었다.

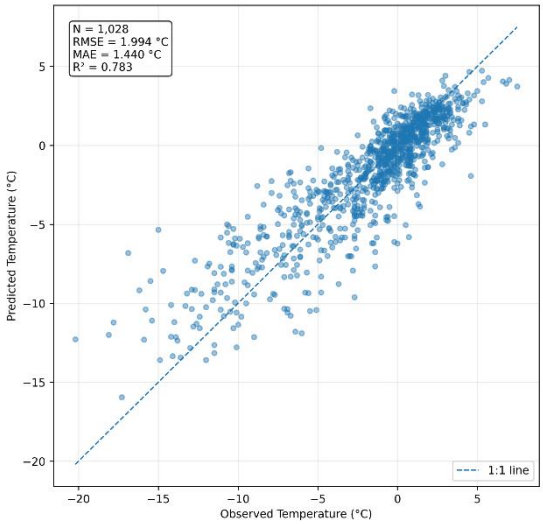


[그림 4.6 NASA 기반 최종모델의 SHAP 변수 영향 분석]

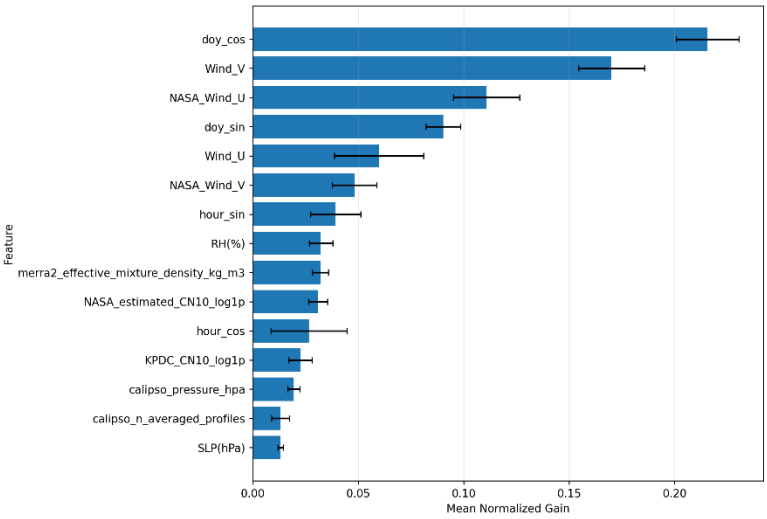
SHAP 분석에서도 계절 순환변수와 바람성분의 영향이 가장 크게 나타났고, CALIPSO 기압, MERRA-2 유효 혼합밀도 및 NASA 추정 CN10이 추가적인 예측정보를 제공하였다. 이는 지상 기상관측변수를 입력하지 않은 조건에서도 NASA 자료가 세종과학기지 지상기온의 계절적 · 기상학적 변동을 일정 수준 설명할 수 있음을 보여준다.

4.3 KPDC-NASA 결합 기온예측모델 성능

KPDC-NASA 결합 기온예측모델은 CALIPSO · MERRA-2 자료와 동일 시점의 KPDC 지상 관측자료가 결합된 1,028개 표본을 이용하여 중첩 연도 교차검증으로 성능을 평가하였다. 외부 시험연도 10개에 대한 평균 성능은 MAE 1.441±0.150℃, RMSE 1.986±0.226℃, R^2 0.771±0.047로 나타났다. 전체 외부 시험예측을 통합한 결과에서는 MAE 1.440℃, RMSE 1.994℃, R^2 0.783이었으며, 평균 편향은 -0.047℃로 전반적인 과대 · 과소예측 편향은 크지 않았다. 연도별 RMSE는 1.669~2.464℃ 범위로, 2019년의 예측오차가 가장 작고 2011년의 오차가 가장 크게 나타났다.

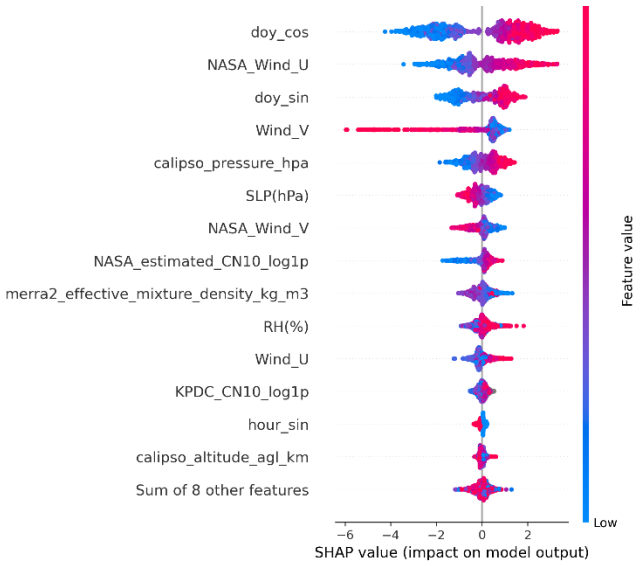


[그림 4.7 KPDC-NASA 결합기반 기온예측모델의 외부 시험자료 실제값-예측값 분포]



[그림 4.8 KPDC-NASA 결합 기반 Gain 중요도]

실제기온과 예측기온은 전반적으로 1:1 기준선을 따라 분포하였으나, 극단적인 저온과 고온에서는 예측값이 평균적인 기온 범위로 일부 수렴하는 경향이 확인되었다. 평균 Gain 기준으로는 doy_cos, KPDC 남북 바람성분 Wind_V, NASA 동서 바람성분 NASA_Wind_U 및 doy_sin의 중요도가 높게 나타났다.

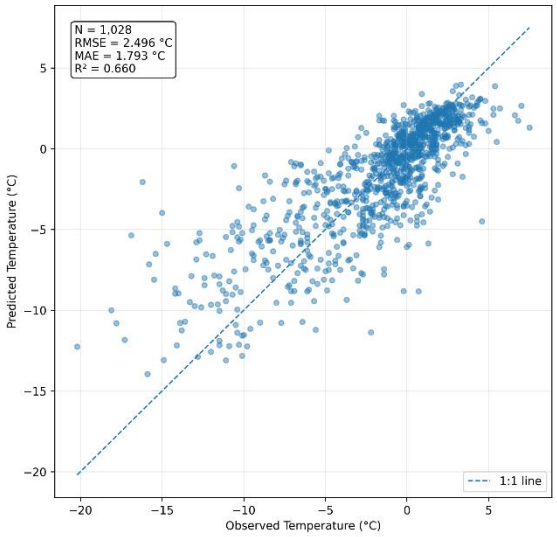


[그림 4.9 KPDC-NASA 결합기반 최종모델의 SHAP 변수 영향 분석]

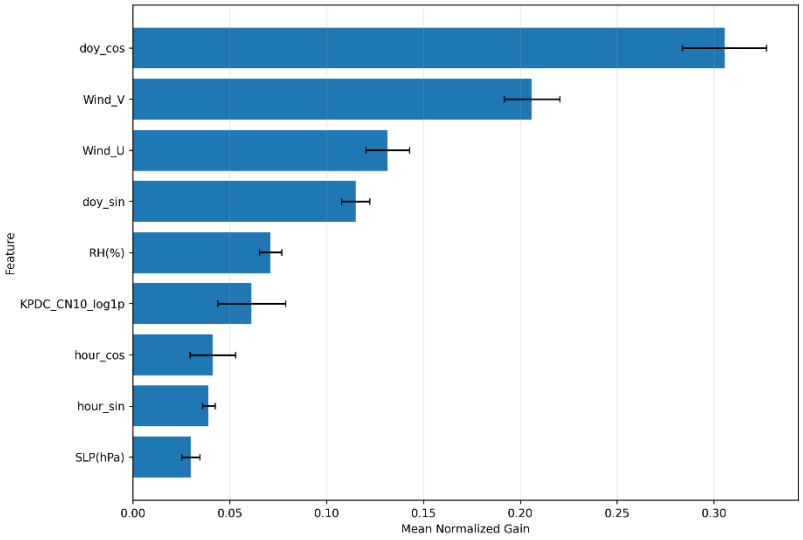
SHAP 분석에서도 계절 순환변수와 양 자료원의 바람성분이 가장 큰 영향을 보였으며, CALIPSO 기압, KPDC 해면기압, NASA 추정 CN10과 유효 혼합밀도 역시 예측에 기여하였다. 이는 결합모델이 계절성과 대기 흐름을 중심으로 학습하면서 KPDC 지상자료와 NASA 위성 · 재분석자료의 정보를 함께 활용하였음을 알 수 있다.

4.4 NASA 기반 KPDC 자료 기온예측모델 성능

NASA 기반 KPDC 자료 기온예측모델은 NASA 관측시점에 맞추어 추출한 KPDC 지상 관측자료 1,028개를 이용하여 중첩 연도 교차검증으로 성능을 평가하였다. 외부 시험연도 10개에 대한 평균 성능은 MAE 1.796±0.207℃, RMSE 2.477±0.366℃, R^2 0.644±0.096으로 나타났다. 전체 외부 시험예측을 통합한 결과에서는 MAE 1.793℃, RMSE 2.496℃, R^2 0.660이었으며, 평균 편향은 -0.036℃로 전체적인 과대·과소예측 편향은 크지 않았다. 연도별 RMSE는 2.000~3.097℃ 범위로, 2018년의 예측오차가 가장 작고 2010년의 오차가 가장 크게 나타났다.

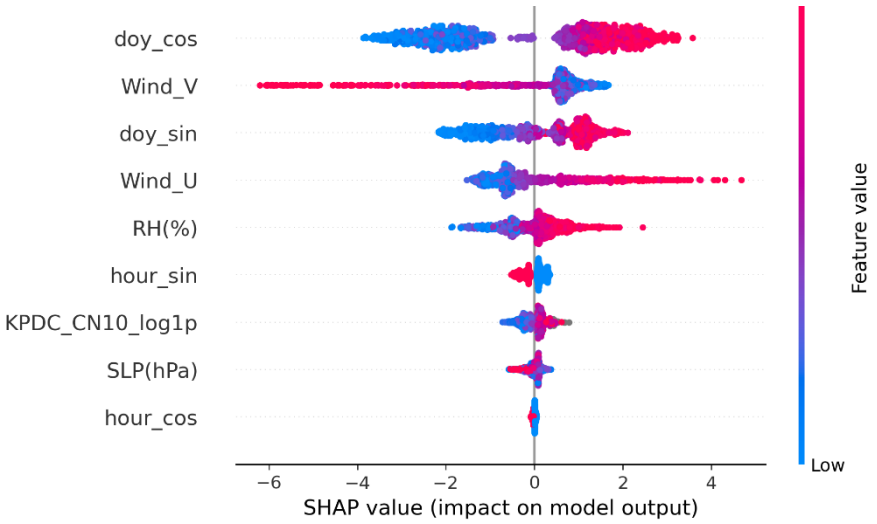


[그림 4.10 NASA 기반 KPDC 자료 기온예측모델의 외부 시험자료 실제값-예측값 분포]



[그림 4.11 NASA 기반 KPDC 자료 기온예측모델의 Gain 중요도]

실제기온과 예측기온은 전반적으로 양의 상관관계를 보였으나, 극저온에서는 실제값보다 높게, 고온에서는 실제값보다 낮게 예측되는 평균 회귀 경향이 확인되었다. 평균 Gain 기준 변수 중요도는 doy_cos, 남북 바람성분 Wind_V, 동서 바람성분 Wind_U, doy_sin 순으로 높게 나타났다.



[그림 4.12 NASA 기반 KPDC 자료 최종모델의 SHAP 변수 영향 분석]

SHAP 분석에서도 계절 순환변수와 바람성분이 모델 예측에 가장 크게 기여하였으며, 상대습도와 CN10은 이를 보완하는 변수로 활용되었다. 이는 NASA 관측시점으로 제한된 희소한 KPDC 표본에서도 계절성과 풍계 정보가 지상기온 변동을 설명하는 핵심 요인으로 작용했음을 보여준다.

4.5 네 모델의 성능 비교 및 주요변수 해석

4.5.1 KPDC_ONLY vs KPDC_MATCHED (KPDC matched = NASA 기반 KPDC 자료 기온예측모델)

KPDC_ONLY와 KPDC_MATCHED는 상대습도, 기압, 바람성분, CN10 및 시간변수로 구성된 동일한 9개 입력변수를 사용하였으나, 학습자료의 범위에서 차이가 있다.

먼저 KPDC_ONLY는 2010~2019년 전체 지상자료 87,642개를 사용한 반면, KPDC_MATCHED는 NASA 관측시점과 대응되는 1,028개 표본만을 사용하였다. 중첩연도 교차검증 평균 성능은 KPDC_ONLY가 MAE 1.719℃, RMSE 2.449℃, R^2 0.635였으며, KPDC_MATCHED는 MAE 1.796℃, RMSE 2.477℃, R^2 0.644로 나타났다. KPDC_MATCHED의 MAE는 0.077℃, RMSE는 0.028℃ 증가하여 전체표본 모델보다 오차가 각각 약 4.5%와 1.2% 높았으나, 평균적인 성능 차이는 크지 않았다.

반면 RMSE의 연도별 표준편차는 KPDC_ONLY 0.293℃, KPDC_MATCHED 0.366℃로 나타나, 희소한 관측시점으로 제한된 모델에서 연도별 성능 변동이 더 크게 나타났다. 연도별 RMSE를 비교한 결과, 두 모델은 각각 5개 연도에서 더 낮은 값을 보였으므로 특정 모델이 모든 연도에서 일관되게 우수한 결과를 보이지는 않았다. 또한 두 모델 모두 doy_cos, Wind_V, Wind_U, doy_sin이 주요 변수로 나타나, 표본 수가 크게 감소한 이후에도 계절성과 풍계 중심의 예측구조는 대체로 유지되었다. 따라서 두 모델의 차이는 자료원 자체의 차이라기보다 표본 수, 관측밀도 및 NASA 관측시점의 선택적 분포에 따른 영향으로 해석할 수 있다.

4.5.2 KPDC_MATCHED vs NASA_ONLY

KPDC_MATCHED와 NASA_ONLY는 NASA 관측시점에 대응하는 동일한 1,028개 표본과 동일한 외부 시험연도를 사용하므로, 지상 관측자료와 NASA 자료의 예측력을 직접 비교할 수 있다.

KPDC_MATCHED의 평균 성능은 MAE 1.796℃, RMSE 2.477℃, R^2 0.644였으며, NASA_ONLY는 각각 1.618℃, 2.283℃, 0.700으로 나타났다. NASA_ONLY는 KPDC_MATCHED보다 MAE가 0.178℃, RMSE가 0.194℃ 감소하여 오차가 각각 약 9.9%와 7.8% 낮았고, R^2 는 0.055 증가하였다. 연도별 RMSE를 비교한 결과 NASA_ONLY가 2010~2013년, 2015~2016년 및 2019년의 총 7개 연도에서 더 낮은 오차를 기록하였다.

또한 RMSE의 연도별 표준편차는 KPDC_MATCHED 0.366℃, NASA_ONLY 0.301℃로, NASA_ONLY의 성능 변동성이 상대적으로 작게 나타났다. 두 모델 모두 계절 순환변수와 바람성분의 중요도가 높았으나, NASA_ONLY에서는 NASA 바람성분과 CALIPSO 기압, MERRA-2 유효 혼합밀도 및 추정 CN10이 추가적인 예측정보로 활용되었다. 이는 본 연구의 공통 관측시점에서는 NASA 위성·재분석자료가 제한된 KPDC 지상자료보다 기온변동을 상대적으로 더 잘 설명했음을 의미한다.

4.5.3 KPDC_MATCHED vs NASA_KPDC

KPDC_MATCHED와 NASA_KPDC는 동일한 1,028개 표본, 동일한 목표기온 및 동일한 외부 시험연도를 사용하며, 결합모델에는 기존 9개 KPDC 입력변수에 NASA 변수 13개가 추가되었다.

KPDC_MATCHED의 평균 성능은 MAE 1.796℃, RMSE 2.477℃, R^2 0.644였으나, NASA_KPDC는 각각 1.441℃, 1.986℃, 0.771로 개선되었다. NASA 변수를 추가함에 따라 MAE는 0.355℃, RMSE는 0.491℃ 감소하여 두 오차지표가 모두 약 19.8% 낮아졌으며, R^2 는 0.127 증가하였다. 연도별 비교에서도 NASA_KPDC는 2010~2019년의 모든 외부 시험연도에서 KPDC_MATCHED보다 낮은 MAE와 RMSE, 높은 R^2 를 기록하였다. 특히 연도별 RMSE 표준편차도 0.366℃에서 0.226℃로 감소하여, 평균성능뿐 아니라 연도에 따른 성능 변동도 완화된 것으로 나타났다. SHAP 분석에서는 KPDC의 남북 바람성분과 해면기압뿐 아니라 NASA 동서 바람성분, CALIPSO 기압, NASA 추정 CN10 및 MERRA-2 유효 혼합밀도가 주요 예측정보로 활용되었다.

이는 NASA 자료가 저층 대기 상태와 공간적 대기 흐름에 관한 보완 정보를 제공했음을 보여준다. 따라서 공통표본 조건에서 NASA 자료를 결합한 것은 지상자료 단독모델의 기온예측 정확도와 연도별 안정성을 동시에 향상시킨 것으로 해석할 수 있다.

4.6 최적 하이퍼파라미터 기반 최종모델 선정 및 생성

각 모델은 외부 시험연도에 대한 중첩 교차검증에서는 시험연도별로 내부 교차검증에서 검증 RMSE가 가장 낮게 나타난 하이퍼파라미터 조합을 적용한 후, 해당 모델이 사용할 수 있는 전체자료로 다시 학습하여 최종모델을 생성하였다. KPDC_ONLY는 87,642개의 장기 지상 관측자료와 9개 입력변수를 사용한 모델로, 기온 추정과 실제 센서 결측에 대응할 수 있는 기본모델로 구성하였다. KPDC_MATCHED는 NASA 관측시점에 대응하는 KPDC 자료 1,028개와 동일한 9개 변수를 사용하여, 공통표본 조건에서 다른 모델과 비교하기 위한 기준모델로 생성하였다. NASA_ONLY는 1,028개 표본과 17개 NASA 입력변수를 사용하여, 지상 입력자료 없이 위성·재분석자료만으로 기온을 추정할 수 있도록 구성하였다. NASA_KPDC는 동일한 1,028개 표본에 KPDC와 NASA의 22개 변수를 함께 사용하여 두 자료원의 결합효과를 반영하였다. 네 모델의 평균 RMSE는 KPDC_ONLY 2.449℃, KPDC_MATCHED 2.477℃, NASA_ONLY 2.283℃, NASA_KPDC 1.986℃로 나타났으며, MAE와 R^2 를 함께 고려한 결과 NASA_KPDC가 최종 성능 최적모델로 선정되었다.

모델	KPDC ONLY	KPDC MATCHED	NASA ONLY	NASA+KPDC
학습 표본 수	87,642	1,028	1,028	1,028
입력변수 개수	9	9	17	22
N estimators	536	286	902	378
Learning rate	0.01	0.02	0.01	0.05
Max depth	5	4	4	5
Min child weight	50	3	3	8
subsample	1.0	0.8	0.8	0.8
Colsample bytree	0.80	0.90	0.85	0.80
Reg alpha	0.01	2.00	0.00	0.50
Reg lambda	0.5	5.0	10.0	5.0
gamma	0.0	0.1	1.0	0.1

[표 4.1 모델별 최종모델 하이퍼파라미터]

최종 모델들은 각각 JSON과 Joblib 형식으로 저장하였다.

* 제출파일

[KPDC_MATCHED_FINAL_bundle.joblib]

[KPDC_ONLY_FINAL_bundle.joblib]

[NASA_KPDC_FINAL_bundle.joblib]

[NASA_ONLY_FINAL_bundle.joblib]

[KPDC_MATCHED_FINAL_metadata.json]

[KPDC_ONLY_FINAL_metadata.json]

[NASA_KPDC_FINAL_metadata.json]

[NASA_ONLY_FINAL_metadata.json]

* 모델 코드 및 코드 html

[XGBoost_Temperature_Prediction_Models_code]

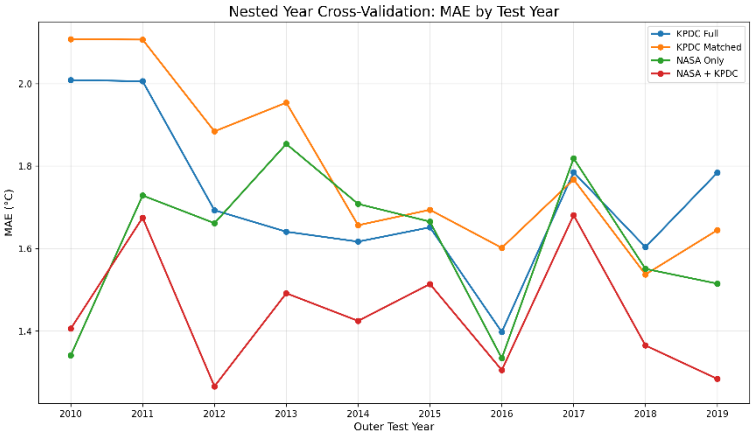
[XGBoost_Temperature_Prediction_Models_code_html]

5. 논의 및 결론

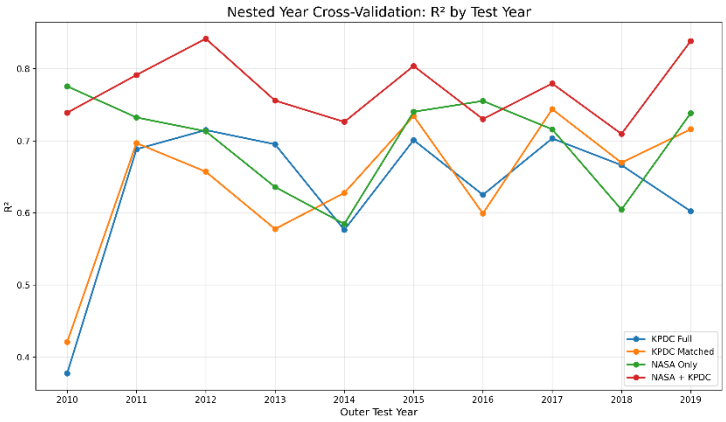
5.1 연구결과의 종합 해석

본 연구에서는 KPDC 전체자료, NASA 관측시점의 KPDC 자료, NASA 자료 및 KPDC-NASA 결합자료를 이용하여 네 가지 XGBoost 기온예측모델을 구축하고 중첩 연도 교차검증으로 성능을 평가하였다. KPDC_ONLY는 87,642개의 지상자료를 활용하여 평균 RMSE 2.449℃를 기록하였으며, 기온 추정과 결측치 보완이라는 실용적 기본모델로서의 가능성을 확인하였다. 동일한 입력변수를 1,028개의 NASA 관측시점으로 제한한 KPDC_MATCHED는 평균 RMSE 2.477℃로 전체자료 모델과 평균오차는 유사했으나, 연도별 성능 변동이 더 크게 나타났다. 동일한 1,028개 시점에서 NASA_ONLY는 RMSE 2.283℃, R^2 0.700으로 KPDC_MATCHED보다 높은 성능을 보여 위성·재분석자료만으로도 지상기온을 일정 수준 추정할 수 있음을 확인하였다.

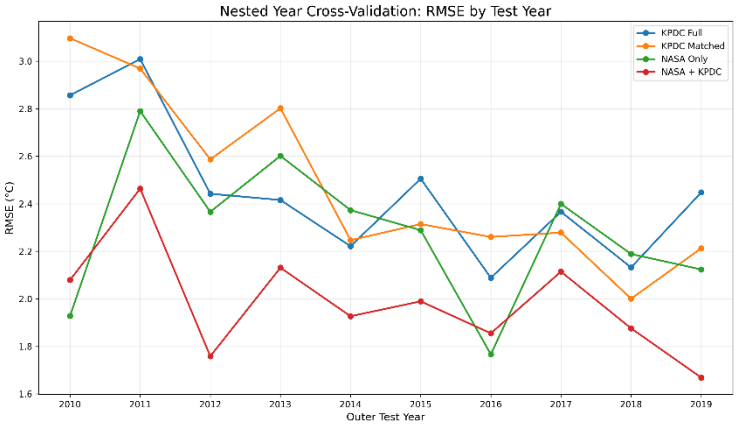
[네 모델에 대한 성능 종합 그래프]



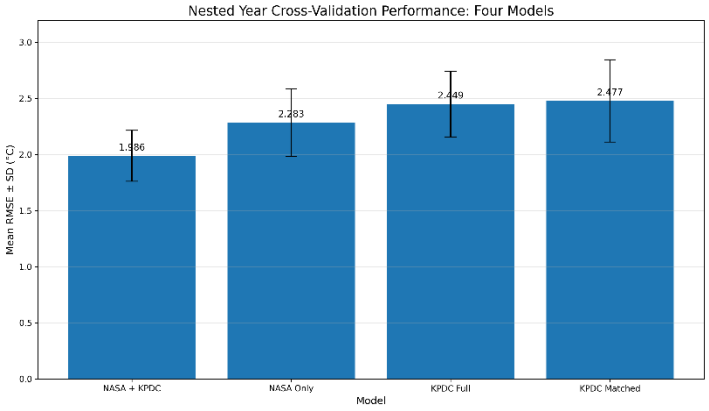
[그림 5.1 네 모델에 대한 각 연도별 MAE 값]



[그림 5.2 네 모델에 대한 각 연도별 R^2 값]



[그림 5.3 네 모델에 대한 각 연도별 RMSE 값]



[그림 5.4 네 모델에 대한 평균 RMSE 및 표준편차 막대그래프]

KPDC-NASA 결합모델은 MAE 1.441℃, RMSE 1.986℃, R^2 0.771로 네 모델 가운데 가장 우수한 평균성능을 기록하였다. 특히 결합모델은 동일 표본의 KPDC_MATCHED 모델보다 MAE와 RMSE를 각각 약 19.8% 감소시키고 R^2 를 0.127 높였으며, 10개 외부 시험연도 모두에서 성능이 개선되었다.

네 모델에서 계절 순환변수와 바람성분이 공통적으로 중요하게 나타났으며, 결합모델에서는 CALIPSO 기압, NASA 추정 CN10 및 MERRA-2 유효 혼합밀도가 추가적인 예측정보로 활용되었다.

이러한 성능 차이는 각 자료가 포착하는 대기현상의 공간적 범위와 물리적 정보가 서로 달랐기 때문으로 해석된다. 세종과학기지는 극전선대에 위치하여 저기압이 빈번하게 통과하고, 계절에 따라 북서풍과 남동풍의 우세가 달라지므로 연중일 순환변수와 바람성분이 기온변동을 설명하는 핵심 변수로 나타난 것으로 판단된다. 특히 남극반도에서는 북쪽의 상대적으로 따뜻한 공기와 남쪽의 찬 공기가 풍향에 따라 이류되면서 큰 기온차를 만들기 때문에, 두 바람성분의 중요도가 모든 모델에서 높게 나타난 결과는 지역의 기상학적 특성과 일치한다.

NASA_ONLY가 KPDC_MATCHED보다 높은 성능을 보인 것은 NASA 자료가 국지적인 단일지점 관측을 넘어 기압·바람·대기밀도 등 넓은 공간과 대기층의 상태를 함께 반영하여, 관측시점의 기단과 종관규모 순환을 보다 구체적으로 구분했기 때문으로 추정된다. MERRA-2와 같은 재분석자료는 다양한 관측자료를 동화하여 시공간적으로 일관된 대기장을 제공하며, 실제 남극 기온평가에서도 관측소가 부족한 지역의 기온변동을 설명하는 유용한 자료로 보고되었다. 반면 KPDC 자료는 세종기지의 실제 지표 부근 상태를 직접 반영하므로, NASA 자료가 충분히 표현하지 못하는 국지적 습도·기압·풍계와 지상 CN10 정보를 보완한 것으로 판단된다. 따라서 결합모델은 KPDC의 국지적 정확성과 NASA 자료의 공간적·입체적 대기정보를 동시에 학습함으로써 개별 자료에서 부족한 설명 정보를 보완하였으며, 이러한 상호보완성이 평균오차 감소와 모든 시험연도에서의 성능 향상으로 이어진 것으로 해석할 수 있다. 이는 지상관측과 위성·재분석자료의 융합이 단일 자료원보다 연속성과 공간대표성을 함께 높일 수 있다는 기존 다중자료 기온추정 연구와도 부합한다.

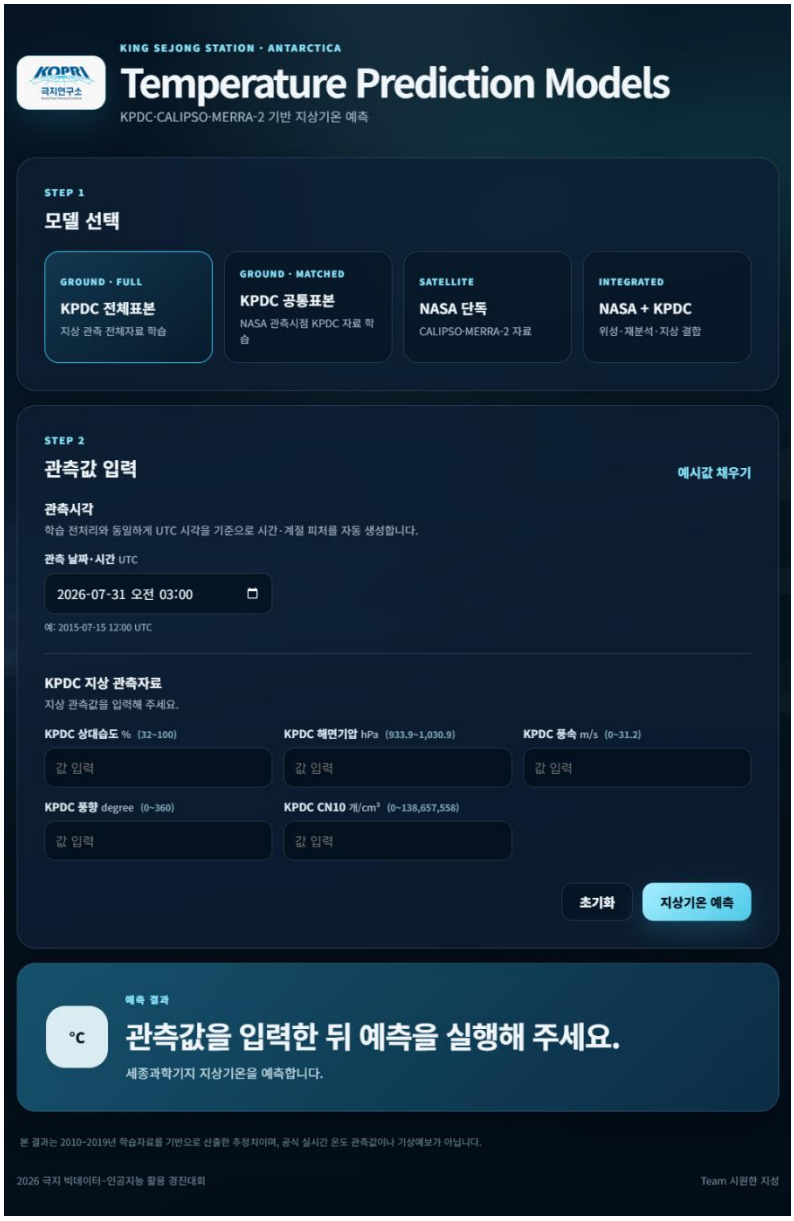
종합하면, 각 모델은 활용 목적에 따라 상호보완적인 역할을 갖는 것으로 해석할 수 있다. NASA 자료와 KPDC 자료가 결합된 모델은 공통 관측시점에서 가장 높은 예측 정확도와 안정성을 제공하였으며, KPDC_ONLY 모델은 연속적인 지상 관측자료를 기반으로 장기간 기온 결측을 보완하는 현장 활용모델로 사용할 수 있고, NASA_ONLY 모델은 지상 입력자료가 제한된 상황에서 보조적인 기온 추정수단으로 활용할 수 있다. 또한 가장 높은 성능을 보인 NASA_KPDC 모델은 두 자료가 동시에 확보되는 시점에서 보다 정확한 기온 추정과 관측값 검증에 활용할 수 있다.

5.2 연구의 의의 및 활용

본 연구는 극지 관측환경에서 기온센서의 고장이나 결측이 발생했을 때, 대기입자와 기상자료를 이용하여 기온을 보완적으로 추정할 수 있는 방법을 제시했다는 데 의의가 있다. 특히 KPDC 지상자료뿐 아니라 CALIPSO 위성자료와 MERRA-2 재분석자료를 결합함으로써, 서로 다른 관측체계가 지닌 정보를 기온예측에 함께 활용할 수 있음을 확인하였다. 또한 구축한 네 모델을 별도의 코딩 없이 사용할 수 있도록 기온예측 사이트를 제작하였다.

* 사이트 주소 : https://krjiseong.github.io/polartempredict/

* 사이트 명 : “Temperature Prediction Models”



[그림 5.5 사이트 개요]

네 가지 모델 중, 적용할 모델을 선택하고 날짜·시간, 기상요소 및 CN10 등 필요한 값을 입력한 뒤 예측 버튼을 눌러 세종과학기지의 추정기온을 확인할 수 있다. 이 시스템은 향후 극지 관측자료의 품질관리센서 이상 시 관측값 검증 및 장기간 결측자료 보충 업무를 지원하는 보조 도구로 활용될 수 있다.

5.3 연구의 한계 및 후속 연구방향 제시

먼저, CALIPSO는 위성의 관측궤도와 통과시각이 정해져 있어 세종과학기지 인근의 원하는 시점에서 연속적인 자료를 확보하기 어렵다는 한계가 있다. 이에 따라 NASA 기반 모델은 KPDC 자료와 동시에 존재하는 1,028개 표본만을 사용하였으며, 일부 계절·시간대 및 극한기상 조건이 충분히 포함되지 않았을 가능성이 있다. 향후에는 분석기간을 현재의 2010~2019년보다 확대하여 CALIPSO 관측사례를 추가로 확보하고, 기간 확대에 따라 표본분포와 모델성능이 어떻게 변화하는지 비교할 필요가 있다. 또한 계절, 기온구간 및 기상상황별 성능을 세분화함으로써 결합모델이 안정적으로 작동하는 조건을 보다 구체적으로 규명할 수 있다.

다음으로 본 연구는 기온·기상요소·에어로졸 자료의 기간과 연속성을 종합적으로 고려하여 세종과학기지를 연구대상으로 선정하였다. 현재 KPDC의 기지 위치 메타데이터를 기준으로 확인되는 자료는 세종과학기지 28개, 장보고과학기지 16개, 다산과학기지 15개로 세종과학기지의 관련 자료가 상대적으로 풍부하게 구축되어 있다. 장보고과학기지와 다산과학기지는 본 연구에 필요한 변수와 장기간 동시관측자료가 상대적으로 제한되어 이번 분석에서는 제외하였다. 향후 두 기지의 기상·대기입자 자료가 충분히 축적되면 동일한 연구절차로 기지별 기온 예측모델을 구축하고, 기지 간 성능비교와 외부검증을 통해 모델의 공간적 일반화 가능성을 평가할 수 있다.

마지막으로 현재 KPDC에서 공개·제공 가능한 자료의 범위에서는 NASA 자료와 동일 시점에 대응하는 현장 에어로졸 입경분포 및 성분별 밀도자료를 충분히 확보하기 어려웠다. 따라서 NASA 에어로졸 질량농도를 CN10으로 환산하는 과정에서 등가 유효반지름과 혼합밀도에 관한 가정을 적용하였으며, 산출된 NASA 추정 CN10은 실제 지상관측 CN10과 완전히 동일한 물리량이라기보다 두 자료의 비교와 결합을 위해 산출한 추정값이라는 한계가 있다. 본 연구에서는 확보 가능한 자료를 활용하여 환산계수를 검증하고 적용하였으나, 향후 현장 입경분포와 성분별 밀도자료가 추가로 확보된다면 환산과정을 더욱 정교화할 수 있다. 나아가 계절과 기단 조건별로 유효반지름 및 혼합밀도를 차등 적용하여 NASA 추정 CN10의 물리적 정확성과 결합모델의 예측성능을 개선하는 후속 연구가 이루어질 수 있다.

6. 참고문헌

1. Chen, T., & Guestrin, C. (2016). XGBoost: A scalable tree boosting system. In *Proceedings of the 22nd ACM SIGKDD International Conference on Knowledge Discovery and Data Mining* (pp. 785–794). Association for Computing Machinery. [https://doi.org/10.1145/2939672.2939785]

2. Friedman, J. H. (2001). Greedy function approximation: A gradient boosting machine. *The Annals of Statistics, 29*(5), 1189–1232. [https://doi.org/10.1214/aos/1013203451]

3. Breiman, L. (2001). Random forests. *Machine Learning, 45*(1), 5–32. [https://doi.org/10.1023/A:1010933404324]

4. Bergstra, J., & Bengio, Y. (2012). Random search for hyper-parameter optimization. *Journal of Machine Learning Research, 13*, 281–305.

5. Cawley, G. C., & Talbot, N. L. C. (2010). On over-fitting in model selection and subsequent selection bias in performance evaluation. *Journal of Machine Learning Research, 11*, 2079–2107.

6. Roberts, D. R., Bahn, V., Ciuti, S., Boyce, M. S., Elith, J., Guillera-Arroita, G., Hauenstein, S., Lahoz-Monfort, J. J., Schröder, B., Thuiller, W., Warton, D. I., Wintle, B. A., Hartig, F., & Dormann, C. F. (2017). Cross-validation strategies for data with temporal, spatial, hierarchical, or phylogenetic structure. *Ecography, 40*(8), 913–929. [https://doi.org/10.1111/ecog.02881]

7. Scikit-learn developers. (n.d.). *GroupKFold*. Scikit-learn. Retrieved July 30, 2026

[https://scikit-learn.org/stable/modules/generated/sklearn.model_selection.GroupKFold.html]

8. Chai, T., & Draxler, R. R. (2014). Root mean square error (RMSE) or mean absolute error (MAE)? Arguments against avoiding RMSE in the literature. *Geoscientific Model Development, 7*(3), 1247–1250. [https://doi.org/10.5194/gmd-7-1247-2014]

9. Hodson, T. O. (2022). Root-mean-square error (RMSE) or mean absolute error (MAE): When to use them or not. *Geoscientific Model Development, 15*(14), 5481–5487. [https://doi.org/10.5194/gmd-15-5481-2022]

10. Chicco, D., Warrens, M. J., & Jurman, G. (2021). The coefficient of determination R-squared is more informative than SMAPE, MAE, MAPE, MSE and RMSE in regression analysis evaluation. *PeerJ Computer Science, 7*, Article e623. [https://doi.org/10.7717/peerj-cs.623]

11. Box, G. E. P., & Cox, D. R. (1964). An analysis of transformations. *Journal of the Royal Statistical Society: Series B (Methodological), 26*(2), 211–243. [https://doi.org/10.1111/j.2517-6161.1964.tb00553.x]

12. Lundberg, S. M., & Lee, S.-I. (2017). A unified approach to interpreting model predictions. In I. Guyon et al. (Eds.), *Advances in Neural Information Processing Systems* (Vol. 30, pp. 4765–4774). Curran Associates, Inc.

13. Winker, D. M., Pelon, J., Coakley, J. A., Jr., Ackerman, S. A., Charlson, R. J., Colarco, P. R., Flamant, P., Fu, Q., Hoff, R. M., Kittaka, C., Kubar, T. L., Le Treut, H., McCormick, M. P., Mégie, G., Poole, L., Powell, K., Trepte, C., Vaughan, M. A., & Wielicki, B. A. (2010). The CALIPSO mission: A global 3D view of aerosols and clouds. *Bulletin of the American Meteorological Society, 91*(9), 1211–1229. [https://doi.org/10.1175/2010BAMS3009.1]

14. Gelaro, R., McCarty, W., Suárez, M. J., Todling, R., Molod, A., Takacs, L., Randles, C. A., Darmenov, A., Bosilovich, M. G., Reichle, R., Wargan, K., Coy, L., Cullather, R., Draper, C., Akella, S., Buchard, V., Conaty, A., da Silva, A. M., Gu, W., … Zhao, B. (2017). The Modern-Era Retrospective Analysis for Research and Applications, Version 2 (MERRA-2). *Journal of Climate, 30*(14), 5419–5454. [https://doi.org/10.1175/JCLI-D-16-0758.1]

15. Randles, C. A., da Silva, A. M., Buchard, V., Colarco, P. R., Darmenov, A., Govindaraju, R., Smirnov, A., Holben, B., Ferrare, R., Hair, J., Shinozuka, Y., & Flynn, C. J. (2017). The MERRA-2 aerosol reanalysis, 1980 onward. Part I: System description and data assimilation evaluation. *Journal of Climate, 30*(17), 6823–6850. [https://doi.org/10.1175/JCLI-D-16-0609.1]

16. Cho, H. K., Kim, J., Jung, Y., Lee, Y. G., and Lee, B. Y., “Recent Changes in Downward Longwave Radiation at King Sejong Station, Antarctica,” Journal of Climate, Vol. 21, No. 22, pp. 5764–5776, 2008, doi:10.1175/2008JCLI1876.1.

17. van Wessem, J. M., Reijmer, C. H., van de Berg, W. J., van den Broeke, M. R., Cook, A. J., van Ulft, L. H., and van Meijgaard, E., “Temperature and Wind Climate of the Antarctic Peninsula as Simulated by a High-Resolution Regional Atmospheric Climate Model,” Journal of Climate, Vol. 28, No. 18, pp. 7306–7326, 2015, doi:10.1175/JCLI-D-15-0060.1.

18. Korea Polar Data Center, “Climate Measurement Around the King Sejong Station, Antarctica in 2019,” Korea Polar Research Institute, KOPRI-KPDC-00001202, 2019, doi:10.22663/KOPRI-KPDC-00001202.

19. Korea Polar Data Center, “Aerosol Number Concentration (>10 nm) from King Sejong Station Collected in 2010–2016,” Korea Polar Research Institute, KOPRI-KPDC-00000770, 2017, doi:10.22663/KOPRI-KPDC-00000770.

20. Collow, A., Buchard, V., Chin, M., Colarco, P., Darmenov, A., and da Silva, A., Supplemental Documentation for GEOS Aerosol Products, GMAO Office Note No. 22, Version 1.1, NASA Global Modeling and Assimilation Office, 2023.

21. Randles, C. A., da Silva, A. M., Buchard, V., Colarco, P. R., Darmenov, A. S., Govindaraju, R. C., Smirnov, A., Ferrare, R. A., Hair, J. W., Shinozuka, Y., and Flynn, C. J., “The MERRA-2 Aerosol Reanalysis, 1980 Onward. Part I: System Description and Data Assimilation Evaluation,” Journal of Climate, Vol. 30, No. 17, pp. 6823–6850, 2017, doi:10.1175/JCLI-D-16-0609.1.